

prod.sales.customer_orders

Delta Table | Sales Domain | Owner: Data Platform / Sales Analytics

01 Идентификация и технический контекст

Catalog / Database	prod
Schema	sales
Table	customer_orders
Object type	Managed Delta Table
Environment	Production
Data domain	Sales / Commerce
Owner	Data Platform / Sales Analytics
Purpose	Единая аналитическая таблица заказов клиентов для BI, customer analytics и downstream ML-признаков.

02 Описание объекта

Назначение. Таблица содержит нормализованный аналитический слой заказов: один заказ представлен одной записью, а ключевые атрибуты клиента, суммы, статусы и временные признаки доступны без обращения к operational database.

Комментарий. Данные поступают из e-commerce платформы и CRM. Отменённые заказы не удаляются: их статус сохраняется для исторического анализа. Денежные значения хранятся в EUR.

Заметки. order_id стабилен между загрузками. customer_id может быть NULL для guest checkout. Не использовать таблицу как источник real-time order status: SLA по свежести — до 1 часа.

03 Физическая структура и оптимизация

Параметр	Значение / описание
Partitioning	По order_date — дневные партиции. Основной паттерн запросов: диапазоны дат.
Clustering / Z-Ordering	Z-ORDER BY (customer_id, order_status) после крупных batch-загрузок.
Indexes	Отдельные B-tree индексы не используются; оптимизация выполняется средствами Delta/Databricks.
File optimization	OPTIMIZE выполняется ежедневно; small files контролируются через auto-compaction.
Retention / VACUUM	История Delta — 30 дней; VACUUM RETAIN 168 HOURS по стандарту платформы.
Table properties	delta.autoOptimize.optimizeWrite=true; delta.autoOptimize.autoCompact=true
Statistics	Статистики собираются для часто фильтруемых колонок; планирование запросов использует Delta statistics.

04 Колонки и ограничения

#	Column	Type	Nullable	PK	Comment
1	order_id	STRING	NO	YES	Уникальный идентификатор заказа из e-commerce платформы.
2	customer_id	STRING	YES	NO	Идентификатор клиента; NULL для guest checkout.
3	order_date	DATE	NO	NO	Дата создания заказа; используется для partitioning.
4	order_status	STRING	NO	NO	CREATED, PAID, SHIPPED, COMPLETED, CANCELLED, REFUNDED.
5	currency	STRING	NO	NO	Валюта заказа; для текущего слоя ожидается EUR.
6	subtotal_amount	DECIMAL(18,2)	NO	NO	Сумма товаров до скидок, доставки и налогов.
7	discount_amount	DECIMAL(18,2)	NO	NO	Общая сумма применённых скидок.
8	shipping_amount	DECIMAL(18,2)	NO	NO	Стоимость доставки.
9	tax_amount	DECIMAL(18,2)	NO	NO	Сумма налогов.
10	total_amount	DECIMAL(18,2)	NO	NO	subtotal - discount + shipping + tax.
11	items_count	INT	NO	NO	Количество товарных позиций в заказе.
12	created_at	TIMESTAMP	NO	NO	Timestamp создания заказа в UTC.
13	updated_at	TIMESTAMP	NO	NO	Последнее изменение записи в source system.

Дополнительные ограничения: order_id — PK; UNIQUE(order_id). CHECK: total_amount >= 0, items_count >= 0; currency IN ('EUR').

05 Пайплайны и происхождение данных

Pipeline / Job	Тип	Источник	Режим	Частота	Что делает
bronze_orders_ingest	Ingestion	Kafka / E-commerce	Streaming	Near real-time	Сохраняет сырые order events в bronze.orders_events.
silver_orders_transform	ELT	bronze.orders_events	Micro-batch	15 min	Дедупликация, нормализация статусов и расчёт денежных полей.
gold_customer_orders	ELT	silver.orders	Batch / MERGE	Hourly	Обновляет prod.sales.customer_orders по order_id; обрабатывает late-arriving events.

Lineage: Kafka → bronze.orders_events → silver.orders → prod.sales.customer_orders → BI dashboards / ML features / finance reporting.

06 Доступ и потребители

Consumers	Sales BI, Finance BI, Customer Analytics, churn/CLV feature pipelines
Access policy	Read access для аналитических ролей; write access только у production ELT service principal.
Sensitivity	Internal — содержит customer_id и коммерческие показатели.
SLA / freshness	P95 freshness ≤ 60 минут; ежедневная полнота данных — 99.5%+.
Expected volume	~80M rows; +150-250K orders/day; ~1-2 GB новых данных/day.

07 Качество, мониторинг и эксплуатация

Aspect	Rule / metric	Threshold / expectation	Owner / monitor
Freshness	MAX(updated_at)	< 60 min	Data Platform / DQ job
Uniqueness	COUNT(order_id) vs COUNT(DISTINCT order_id)	100% unique	Data Quality
Nulls	order_id, order_date, total_amount	0% NULL	Data Quality
Amounts	total_amount >= 0	100% pass	Sales Analytics
Status values	order_status domain check	100% valid values	Data Quality
Volume anomaly	Daily row-count deviation	±20% vs 7-day baseline	Platform Monitoring